



A person is holding a smartphone in their hands. The screen of the phone displays a chart titled 'NEW MMR BREAKDOWN'. The chart has a red header and shows some data points, though they are not clearly legible. The background of the image is dark and blurry, showing what appears to be a person's legs and feet.

머신러닝 기반 병원의 규모에 따른 캘리포니아주 응급실 방문자수 예측


박상협

목차

1. 서론
2. 데이터 개요
3. 데이터 전처리 과정
4. 개별 모델 성능 비교
5. 모델 평가 및 분석
6. 결론
7. 참고 문헌



1. 서론 – 배경



* Source: Authors' analysis of Emergency Discharge Data and Patient Discharge Data From the California Office of Statewide Health Planning and Development, 2005-2015. ED, emergency department.



EMERGENCY CARE | January 30, 2026

**A record year: UC Davis
Emergency Department cares
for over 100,000 patients in
2025**

* Source: UC Davis Health, "A record year: UC Davis Emergency Department cares for over 100,000 patients in 2025," January 21, 2026

캘리포니아 주 내의 총 응급실 방문자수는 매년 증가하는 중이며, 특정 지역(Davis, CA)에서는 연간 방문자가 10만명이 넘는 경우도 관찰됨.

1. 서론

– 문제 정의

응급실의 과밀화는 의료 서비스의 질을 직접적으로 저하. 따라서 최적의 자원 배분을 보장하기 위해 병원 규모와 인프라에 따른 환자 수를 정밀하게 예측하는 것이 매우 중요함.


– 분석 목표

본 연구는 머신러닝을 활용하여 응급실 방문에 영향을 미치는 요인들을 분석하고 총 방문자 수를 예측. 이를 바탕으로 병원 응급실 운영의 최적화를 위한 정책적 시사점을 제공하는 것을 목표로 함.



2. 데이터 개요

변수명	변수 분류	설명	데이터 타입	출처
Tot_ED_NmbVsts	타겟 변수	응급실 총 방문자수	연속형	CAL HHS (California Health and Human Services)
CountyName	독립 변수	응급실 위치한 카운티명	명목형	
LICENSED_BED_SIZE		응급실 Station의 크기 범위		
HospitalOwnership		시설 소유 분류		
UrbanRuralDesi		시설위치에 따른 지역 설정		
TEACHINGDesignation		수련병원 여부		
Category		건강 관련 상태		
EDStations		응급실 Station 수	연속형	
EDDXCount		특정 범주별 응급실 방문자수		
LATITUDE		해당 기관 위도		
LONGTITUDE		해당 기관 경도		
PrimaryCareShortageArea		보건의료 인력 부족 지역(1차 의료) 해당 여부	명목형	
MentalHealthShortageArea		보건의료 인력 부족 지역(정신 건강) 해당 여부		
population		각 County 인구수	연속형	

2. 데이터 개요



2. 데이터 개요



총 응급실 방문 횟수는 및 응급실 스테이션 수와 뚜렷한 선형적 관계를 보임.

총 응급실 방문 횟수는 병상 다른 중앙값 분포를 보임. 특히 '300-499'와 같은 그룹에서는 아주 높은 이상치 확인.

2. 데이터 개요 – 변수 선택 (히트맵)



변수명 제거	원인	조치
LONGITUDE, LATITUDE	높은 상관계수 (0.9)	CountyName 사용 (Encoding)
system, oshpd_id, FacilityName2	CountyName와의 다중공선성 문제	
year	해당 변수는 모든 관측치에서 동일한 값을 가짐, 모델의 변별력을 높이는 데 기여하지 못함	제거
Vists_Per_Station	EDDXCount와의 높은 상관계수(0.8). EDDXCount가 타겟 변수와 더 가까움	제거 (EDDXCount 사용)

2. 데이터 개요 – 연속형 변수 기술 통계 분석(n=12849)


변수명	분류	평균	표준편차	최소값	최대값
Tot_ED_NmbVsts	타겟 변수	39642.068	26917.290	511.000	146799.000
EDStations	독립 변수	28.590	20.744	1.000	114.000
EDDXCount		3756252	11414.192	0.000	1467999.000
population		3237328.288	3768433.660	8700.000	10014009.000
LICENSED_BED_SIZE_ENCODED		4.074	1.779	1.000	7.000
log_Tot_ED_NmbVsts		10.311	0.837	6.238	11.897
log_EDStations		3.142	0.730	0.693	4.745
log_EDDXCount		6.184	2.122	0.000	11.897
visits_per_station		1486.463	597.270	166.623	4714.000

2. 데이터 개요 – 명목형 변수 기술 통계 분석(n=12849)

변수명	분류	고유값	최빈값	빈도수
CountyName	독립 변수	53	Los Angeles	2885
HospitalOwnership		3	Nonprofit	7676
UrbanRuralDesi		3	Urban	10019
TEACHINGDesignation		2	Non-Teaching	11608
Category		17	Active COVID-19	757
PrimaryCareShortageArea		2	No	8865
MentalHealthShortageArea		2	No	7687

3. 데이터 전처리 과정 – 결측치

변수명	결측치
Tot_ED_NmbVsts	0
CountyName	0
LICENSED_BED_SIZE	0
HospitalOwnership	0
UrbanRuralDesi	0
TEACHINGDesignation	0
Category	0
EDStations	17
EDDXCount	0
LATITUDE	0
LONGTITUDE	0
PrimaryCareShortageArea	0
MentalHealthShortageArea	0
population	0





중위값 대체

변수명	결측치
Tot_ED_NmbVsts	0
CountyName	0
LICENSED_BED_SIZE	0
HospitalOwnership	0
UrbanRuralDesi	0
TEACHINGDesignation	0
Category	0
EDStations	0
EDDXCount	0
LATITUDE	0
LONGTITUDE	0
PrimaryCareShortageArea	0
MentalHealthShortageArea	0
population	0


* Source : REPLACE WITH MEDIAN VALUE
(Raymond, et al., 2023)

3. 데이터 전처리 과정 – 이상치

Original value



After replacing




필드명	왜도
EDStations	1.3164

필드명	왜도
EDStations	1.3180

* Source : REPLACE WITH MEDIAN VALUE
(Raymond, et al., 2023)

3. 데이터 전처리 과정 – 이상치


LICENSED_BED_SIZE_ENCODED



변환

불필요


EDDXCount



변환

필요


Tot_ED_NmbVsts



변환

필요

EDStations




변환

필요

* Source : YEO-JOHNSON TRANSFORMATION
(Yeo and Johnson, 2000; Devika et al., 2022).

3. 데이터 전처리 과정 – 이상치 (왜도비교)




	변수명	원본 데이터	변환 데이터
값	Tot_ED_NmbVsts	1.000	- 0.05

* Source : YEO-JOHNSON TRANSFORMATION
(Yeo and Johnson, 2000; Devika et al., 2022).


3. 데이터 전처리 과정 – 이상치 (왜도비교)

Distribution Comparison for EDStations

Original: EDStations (Skew: 1.32)



YJ-Transformed: yj_EDStations (Skew: -0.02, λ : 0.15)




	변수명	원본 데이터	변환 데이터
값	EDStations	1.3180	- 0.02

* Source : YEO-JOHNSON TRANSFORMATION
(Yeo and Johnson, 2000; Devika et al., 2022).


3. 데이터 전처리 과정 – 이상치 (왜도비교)

Distribution Comparison for EDDXCount

Original: EDDXCount (Skew: 5.70)



YJ-Transformed: yj_EDDXCount (Skew: 0.00, λ : -0.01)




	변수명	원본 데이터	변환 데이터
값	EDDXCount	5.695	0.000

* Source : YEO-JOHNSON TRANSFORMATION
(Yeo and Johnson, 2000; Devika et al., 2022).

3. 데이터 전처리 과정 - ENCODING

	값 (범위)	ENCODING
LICENSED_BED_SIZE	‘1 - 49 ’	1
	‘ 50 - 99 ’	2
	‘ 100 - 149 ’	3
	‘ 150 - 199 ’	4
	‘ 200 - 299 ’	5
	‘ 300 - 499 ’	6
	‘500+’	7

	값	ENCODING
HospitalOwnership	Nonprofit	Hospital Ownership_Nonprofit
	Investor Owned	Hospital Ownership_Investor Owned
	Government	Hospital Ownership_Government
UrbanRuralDesi	Urban	Urban Rural Desi_Urban
	Rural	Urban Rural Desi_Rural
	Frontier	Urban Rural Desi_Frontier



3. 데이터 전처리 과정 - ENCODING

	값	ENCODING
TEACHING Designation	Non-Teaching	TEACHING Designation_Non-Teaching
	Teaching	TEACHING Designation_Teaching
Primary Care Shortage Area	Yes	Primary Care Shortage Area_Yes
	No	Primary Care Shortage Area_No
Mental Health Shortage Area	Yes	Mental Health Shortage Area_Yes
	No	Mental Health Shortage Area_No

3. 데이터 전처리 과정 - ENCODING

대분류 값	소분류 값	ENCODING	값	ENCODING
Category	Active COVID-19	Category_Active COVID-19	Asthma	Category_Asthma
	Diabetes	Category_Diabetes	Cancer	Category_Cancer
	Pneumonia	Category_Pneumonia	Sepsis	Category_Sepsis
	Obesity	Category_Obesity	COPD	Category_COPD
	Mental Health	Category_Mental Health	Respiratory	Category_Respiratory
	Hypertension	Category_Hypertension	COVID-19 History	Category_COVID-19 History
	All ED Visits	Category_All ED Visits	Homeless	Category_Homeless
	Substance Abuse	Category_Substance Abuse	Cardiac	Category_Cardiac
	Stroke	Category_Stroke		

4.개별 모델 성능 비교 – 세팅

파라미터 세팅	값	설명
TARGET	yj_Tot_ED_NmbVsts	
TRAIN_SIZE	0.75	Train data : 75% (9636 EA), Validation Data : 25%(3213 EA)
FOLD	5	Cross Validation (For Ensemble)
IGNORE_FEATURES	‘Tot_ED_NmbVsts’, ‘EDStations’, ‘EDDXCount’, ‘oshpd_id’, ‘FacilityName2’	
NORMALIZE	TRUE	
NORMALIZE_METHOD	ZSCORE	

4.개별 모델 성능 비교 (Yeo-Johnson 변환 스케일 기준)

MODEL	MAE	MSE	RMSE	R2	RMSLE	MAPE
Extreme Gradient Boosting	3.1183	16.9470	4.1166	0.9587	0.0335	0.0262
Random Forest Regressor	3.3748	19.2461	4.3863	0.9838	0.0362	0.0287
CatBoost Regressor	3.0356	19.4328	4.4075	0.9836	0.0358	0.0256
Light Gradient Boosting Machine	3.6431	22.5624	4.7483	0.9810	0.0416	0.0317
Extra Trees Regressor	3.5853	27.7692	5.2694	0.9766	0.0426	0.0302
Decision Tree Regressor	3.4453	29.4453	5.4234	0.9752	0.0439	0.0290
Gradient Boosting Regressor	7.7573	102.5820	10.1206	0.9136	0.0871	0.0678
AdaBoost Regressor	10.9017	197.4806	14.0505	0.8336	0.1277	0.0977
Lasso Least Angle Regression	10.9039	197.4801	14.0505	0.8336	0.1276	0.0977
Lasso Regression	10.9020	197.4802	14.0505	0.8336	0.1277	0.0977

- Base Model Algorithm : XGBoost (Based on result)

* Source : Evaluated based on R2 & RMSE
(Source: Z. Mekni , et al., 2023)

4.개별 모델 성능 비교 – 보팅

FOLD	MAE	MSE	RMSE	R2	RMSLE	MAPE
0	3.1315	17.4212	4.1739	0.9848	0.0342	0.0265
1	3.1406	17.5422	4.1883	0.9850	0.0340	0.0263
2	3.2113	17.6941	4.2064	0.9852	0.0345	0.0272
3	3.2400	18.0736	4.2513	0.9853	0.0348	0.0275
4	3.1327	17.5111	4.1846	0.9854	0.0342	0.0266
Mean	3.1712	17.6484	4.2009	0.9851	0.0343	0.0268
Std	0.0455	0.2301	0.0273	0.0002	0.0003	0.0005

5.모델평가 및 분석 – 하이퍼파라미터 튜닝


단계	과정	하이퍼파라미터	튜닝 전	튜닝 후
1	기본 모델 선택	LEARNING_RATE	0.3	0.010
2	하이퍼파라미터 튜닝을 통한 성능 극대화	MAX_DEPTH	6	9
3	교차검증을 통한 과적합 검사	SUBSAMPLE	1	0.9

최종 알고리즘	MAE	MSE	RMSE	R2	RMSLE	MAPE
튜닝 전	3.0669	15.9328	3.9916	0.9856	0.0324	0.0255
튜닝 후	2.9305	15.3323	3.9157	0.9862	0.0315	0.0243


● 하이퍼파라미터 튜닝 결과 : R2 (0.9856 → 0.9862), RMSE (3.9916 → 3.9157)

* Source : Evaluated based on R2 & RMSE
(Source: Z. Mekni , et al., 2023)

5.모델평가 및 분석 – 최종 알고리즘 VS 앙상블 모델



VOTING
과적합




XGBOOST
일반화

모델	MAE	MSE	RMSE	R2	RMSLE	MAPE
XGBOOST	3.0669	15.9328	3.9916	0.9856	0.0324	0.0255
VOTING	3.2213	17.8322	4.2228	0.9839	0.0342	0.0269

● XGBOOST가 앙상블 모델보다 높은 R²값과 낮은 RMSE값을 갖고있음
→ 최종 모델 알고리즘 : XGBOOST


* Source : Evaluated based on R2 & RMSE
(Source: Z. Mekni , et al., 2023)

5.모델평가 및 분석 – 모델 일반화 과정



예측 오차

$R^2 = 0.986$



잔차

Train $R^2 = 0.992$


Test $R^2 = 0.986$

최종 모델	RMSE	R2
TRAIN DATA SET	0.067	0.994
VALIDATION DATA SET	0.085	0.989

- 최종 모델은 검증 데이터에서 $R^2 = 0.9862$, $RMSE = 3.9157$ 를 기록하였으며, 이는 통계적 안정성을 보임


* Source : Evaluated based on R2 & RMSE
(Source: Z. Mekni , et al., 2023)

5.모델 평가 및 분석 - FEATURE IMPORTANCE



● 상위 8개 특성(feature)이 누적 특성 중요도의 90% 이상을 차지


5.모델 평가 및 분석- SHAP



변수	영향
log_EDStations	영향력이 가장 큼. SHAP 값에 비례하여 결정
CountyName	병원이 어디에 있느냐에 따라 (결과가) 다양
LICENSED_BED_SIZE_ENCODED	병상 수가 적은 병원일수록 예측치가 낮음
Category_	타겟 변수에 거의 영향 없음

* 언급 변수들은 예측 모델에서의 기여도를 나타낸 것이며, 실제 타겟 변수와의 인과 관계는 다를 수 있음.


5.모델 평가 및 분석- SHAP



해석

모델은 응급실 시설 수가 많을수록
방문객 수도 증가한다는 양(+)의
상관관계를 학습.

5.모델 평가 및 분석- SHAP




해석


예측값은 일반적으로 병상 규모가 커짐에 따라 증가하는 경향을 보이지만, 응급실 시설 수준(log_EDStations)에 따라 증폭되거나 완화될 수 있음.

6. 결론 – 분석 활용방안

고이용
병원들



저이용
병원들



도시 및 농어촌 지역에서 응급실 스테이션당 방문객 수가 상위권에 위치한 Kaiser(Anaheim 외), MLK Jr. Community, Southwest Healthcare, Adventist Health Hanford, Palomar Medical Center 등의 의료기관은 현재 응급 의료 수요가 임계점에 도달한 것으로 분석됨. 의료 서비스의 질적 저하를 막기 위해 시설 확충 및 추가 의료 인력 배치 등의 지원 정책 마련에 참고 가능.


Kern Valley, Glenn, Colorado River Medical Center 등 응급실 이용 밀도가 낮은 의료기관들을 대상으로 환자 인계 및 의료 자원 재배치 정책을 수립할 필요성 대두. 저밀도 병원의 인프라를 적극 활용하는 것은 캘리포니아 전역의 응급실(ER) 과포화 문제를 해결하고 의료 자원의 효율적 배분을 실현하는 중요한 전략이 될 것.

* Feature Importance 상위 2개 변수로 구분한 병원들의 총 방문자수 기준

6. 결론 – 의의 및 한계점

의의

주요 영향 요인 구분




병원의 규모나 지리적 위치가 ER 방문자수에 미치는 영향 확인 가능.

병원간 이용 격차 구분



병원별 ER 이용자수 차이를 통해 과밀 병원이나 저이용 병원 구별 가능.

의료 자원 배분 최적화 가능성



ER 이용량과 병원 특성 분석을 통해 의료 자원의 과잉 및 부족 상태를 파악, 효율적인 자원 배분 전략에 기여 가능.

한계점

1. 특정 기간 (2021 - 2023) 동안의 데이터를 사용하여 장기적인 환자들의 방문 패턴 분석이나 돌발적인 의료 트렌드 파악에는 제한 적임.
2. 병원 크기(병상수, Station수 등)에 한정된 분석으로, 기타 외부변수(환자의 정보, 기상 조건 등)의 부재로 인해 병원 방문에 영향을 줄 수 있는 다양한 요인의 누락 가능성이 있어 예측의 깊이가 제한적임.
3. 예측 모델은 정적 분석의 성격을 띠면서, 실시간 ER 환자 예측은 불가능함.

7.참고문헌

참고문헌

Marcilio, I., et al. (2022). "Predicting hospital emergency department visits with deep learning approaches." ResearchGate.

Xie, F., et al. (2018). "Predicting hospital admission at emergency department triage using machine learning." PLOS ONE.

PLOS Digital Health. (2025). "Evaluating fairness of machine learning prediction of prolonged wait times in Emergency Department with Interpretable eXtreme gradient boosting." PLOS.

Wolfson, B. J., & Sánchez, V. G. (2025). "California's Primary Care Shortage Persists Despite Ambitious Moves To Close Gap." California Healthline.

Yeo, I. K., & Johnson, R. A. (2000). "A new family of power transformations to improve normality or symmetry." Biometrika.

Raymond, J. L., et al. (2023). Advanced imputation techniques for missing healthcare data: A focus on median substitution in skewed distributions. Data Science Review.

참고 기사

California Healthline. (2025, October 14). Nursing shortages force rural California hospitals to scale back emergency services, <https://californiahealthline.org>

CalMatters. (2025, August 21). The Great Healthcare Gap: Why 1 in 3 Californians live in areas with too few doctors, <https://calmatters.org>

UC Davis Health. (2026, January 21). A record year: UC Davis ED cares for over 100,000 patients in 2025,, <https://health.ucdavis.edu>

Los Angeles Times. (2025, November 5). California's ERs are at a breaking point as patient volumes soar, <https://latimes.com>